

Pipeline de Preprocesamiento y Diagnóstico

Pre-entrega - Módulo 2

Dataset	AG News
Alumno	Matías Noero
Curso	Data Science III - NLP & Deep Learning
Fecha	25 de julio de 2026

Corpus seleccionado para toda la cadena: Módulos 2, 3 y 4 y Proyecto Final.

1. Dataset y criterio de separación


Se trabajó con AG News, el corpus provisto por la cátedra para clasificación temática de noticias en inglés. El conjunto contiene 8.000 documentos de entrenamiento y 2.000 de test, con las categorías World, Sports, Business y Sci_Tech. Este EDA utiliza exclusivamente ag_news_train.csv. El test queda aislado y no participa del ajuste, la selección de parámetros ni el diagnóstico, evitando data leakage.

2. Pipeline de preprocesamiento

1. Decodificación: conversión de entidades HTML. **2. Limpieza estructural:** eliminación de etiquetas HTML, URLs, dominios, correos y caracteres no alfabéticos. **3. Normalización:** minúsculas y espacios uniformes. **4. Análisis lingüístico:** tokenización y lematización con SpaCy (en_core_web_sm). **5. Filtrado:** puntuación, espacios, stop-words y boilerplate de agencias (AP, AFP y Reuters). Se preservan las negaciones no, not, never y nor para no perder información semántica.


Control de calidad: no se detectaron valores nulos ni documentos vacíos después del pipeline. Los n-gramas finales no contienen tags HTML ni URLs.

3. Diagnóstico de longitud



La mediana es de **23 tokens** por documento; el promedio, 23,16. El percentil 95 es de **32 tokens**, mientras que el máximo observado es 70. En un modelo posterior, max_len=32 cubriría el 95% del corpus preprocesado y limitaría el costo computacional. Conviene validar ese valor nuevamente con el tokenizador subword del Transformer, porque WordPiece puede aumentar la longitud.

4. Distribución de clases



Cada categoría aporta exactamente 2.000 documentos (25%). El split de entrenamiento está perfectamente balanceado, por lo que no se requieren ponderaciones de clase ni remuestreo en esta etapa. Para los módulos siguientes se mantendrá la evaluación por clase y F1-macro para detectar diferencias de dificultad aunque el soporte sea uniforme.

5. Top 50 de palabras

En las 50 palabras más frecuentes, cuatro coinciden con la lista de stop-words de SpaCy: say, not, no y take. Las negaciones not y no se conservaron deliberadamente. Say y take reaparecen porque algunas formas flexionadas no eran stop-words antes de ser lematizadas; este hallazgo se documenta y podrá evaluarse como ajuste de dominio.

#	Palabra	Frecuencia	Stop-word	#	Palabra	Frecuencia	Stop-word
1	say	1.814	Sí	26	president	408	No
2	new	1.432	No	27	kill	404	No
3	year	850	No	28	lead	402	No
4	company	651	No	29	day	402	No
5	world	609	No	30	high	399	No
6	win	597	No	31	no	396	Sí
7	report	549	No	32	official	365	No
8	game	544	No	33	open	359	No
9	not	531	Sí	34	security	355	No
10	oil	519	No	35	government	354	No
11	monday	518	No	36	season	347	No
12	wednesday	505	No	37	corp	341	No
13	thursday	502	No	38	group	341	No
14	tuesday	495	No	39	share	339	No
15	friday	480	No	40	rise	335	No
16	week	472	No	41	team	333	No
17	price	465	No	42	people	332	No
18	inc	452	No	43	united	332	No
19	time	450	No	44	end	331	No
20	million	447	No	45	state	325	No
21	microsoft	446	No	46	market	316	No
22	plan	443	No	47	service	315	No
23	iraq	441	No	48	sunday	315	No
24	yesterday	424	No	49	stock	315	No
25	york	419	No	50	take	314	Sí

6. Bi-gramas más frecuentes

#	Bi-grama	Frecuencia
1	new york	419
2	oil price	197
3	united states	167
4	prime minister	139
5	official say	115
6	say thursday	102
7	say monday	101
8	red sox	98
9	say tuesday	98
10	los angeles	96
11	san francisco	96
12	president bush	93
13	say wednesday	90
14	say friday	89
15	mobile phone	72
16	wall street	71
17	microsoft corp	70
18	quote profile	69
19	profile research	69
20	world cup	69

Los bi-gramas reflejan señales temáticas útiles: oil price, wall street y microsoft corp se asocian con Business/Sci_Tech; red sox y world cup con Sports; united states, prime minister y president bush con World. Las combinaciones con días y el verbo say responden al estilo periodístico y no a errores estructurales.

7. Tri-gramas más frecuentes

#	Tri-grama	Frecuencia
1	quote profile research	69
2	boston red sox	37
3	new york stock	36
4	high oil price	27
5	press canadian press	26
6	canadian press canadian	26
7	prime minister ariel	26
8	minister ariel sharon	25
9	secretary state colin	22
10	state colin powell	22
11	new york yankees	21
12	president vladimir putin	21
13	president george bush	21
14	security exchange commission	21
15	crude oil price	20
16	international space station	18
17	minister tony blair	17
18	prime minister tony	17
19	st louis cardinal	16
20	oil price rise	15

Los tri-gramas conservan entidades y eventos informativos, por ejemplo boston red sox, security exchange commission, international space station y president george bush. Quote profile research y press canadian press revelan boilerplate editorial residual; se documenta para evitar eliminar palabras potencialmente informativas sin una validación posterior.

8. Conclusión

El pipeline transformó los 8.000 documentos de entrenamiento de AG News en un corpus normalizado, lematizado y sin documentos vacíos. La limpieza eliminó etiquetas HTML, URLs, dominios y marcas repetidas de agencias, y los n-gramas obtenidos muestran expresiones coherentes con las cuatro categorías. Persisten algunas fórmulas editoriales, como quote profile research y press canadian press. No se eliminaron automáticamente porque términos como research o press también pueden aportar señal; su impacto deberá comprobarse mediante validación y no por una decisión arbitraria.

La longitud es compacta: la mediana es 23 tokens y el percentil 95 es 32. Este valor constituye una referencia inicial para max_len, aunque deberá recalcularse con el tokenizador WordPiece del modelo Transformer. El máximo de 70 tokens indica una cola derecha acotada y no se generaron textos vacíos. La distribución de clases es perfectamente balanceada, con 2.000 documentos por categoría; por lo tanto, no se requieren técnicas de remuestreo.

El corpus está listo para el clasificador TF-IDF del Módulo 3. Se guardarán el texto original y el preprocesado para conservar trazabilidad. El vectorizador se ajustará solo con train y el test permanecerá aislado hasta la evaluación final. Como control futuro, se comparará el rendimiento manteniendo y eliminando boilerplate residual, y se revisarán por clase los errores del modelo.

Conclusión: 222 palabras (máximo solicitado: 300).

9. Reproducibilidad y archivos generados

El script asociado genera el CSV preprocesado, el resumen estadístico, las tablas de bi-gramas, tri-gramas y palabras frecuentes, y ambas visualizaciones. La semilla de referencia es 42. El dataset elegido queda fijado como AG News para las pre-entregas restantes y el Proyecto Final.