

PROYECTO FINAL CONSOLIDADO

Modelo de NLP analizado exhaustivamente

Pipeline end-to-end de clasificación de noticias y comparación técnica entre un modelo clásico TF-IDF y un Transformer adaptado eficientemente mediante LoRA.

Alumno	Matías Noero
Curso	Data Scientist III - NLP & Deep Learning
Dataset	AG News · World, Sports, Business y Sci_Tech
Modelos	TF-IDF + LinearSVC · DistilBERT + PEFT/LoRA
Evaluación	Mismo ag_news_test.csv · 2.000 noticias
Fecha	8 de agosto de 2026

F1 Macro baseline 0,8925	F1 Macro LoRA 0,9070	Ganancia absoluta +1,46 pp
---	---------------------------------------	---

Resultado ejecutivo

DistilBERT + LoRA obtuvo el mejor desempeño global, con Accuracy y F1 Macro de 0,9070. La mejora es real y consistente, aunque moderada. Fue lograda entrenando 741.124 parámetros -el 1,095% del modelo- durante 87,7 segundos en una GPU T4. TF-IDF + LinearSVC conserva ventajas claras de simplicidad, interpretabilidad y costo operativo.

Resumen ejecutivo

Este proyecto consolida un pipeline reproducible de clasificación multiclase sobre AG News. El objetivo técnico es contrastar una representación léxica esparsa con una representación contextual basada en embeddings y self-attention. El objetivo aplicado es seleccionar una solución que equilibre calidad predictiva, eficiencia, interpretabilidad y facilidad de despliegue.

Conclusiones principales

- Ambos modelos se evaluaron sobre las mismas 2.000 noticias de test, con 500 observaciones por clase.
- El baseline alcanzó F1 Macro 0,8925; LoRA alcanzó 0,9070, una mejora de 1,46 puntos porcentuales.
- Sci_Tech obtuvo la mayor mejora de F1 por clase: +0,0206; su recall aumentó de 0,8720 a 0,9140.
- Sports fue la categoría más sencilla para ambos modelos; Business continuó siendo la más difícil.
- La frontera Business-Sci_Tech siguió concentrando la mayor ambigüedad temática.
- LoRA ofrece el mejor desempeño cuando existe GPU; TF-IDF es preferible si prima la simplicidad operativa.

Recomendación


Para este caso se recomienda DistilBERT + LoRA como modelo de mayor calidad predictiva, acompañado por monitoreo de latencia y deriva. Se conserva TF-IDF + LinearSVC como baseline productivo, control de regresión y alternativa de bajo costo.

Alcance de la evidencia

Las métricas, tiempos y parámetros de LoRA provienen de la ejecución real en Google Colab. Las métricas del baseline provienen de su pipeline reproducible. El tiempo del baseline no fue instrumentado, por lo que no se presenta una comparación temporal numérica inventada. La interpretabilidad del Transformer es cualitativa: no se calcularon mapas de atención ni SHAP.

1. Definición del problema y dataset

AG News es un corpus de noticias en inglés organizado en cuatro categorías. La muestra utilizada por la cátedra contiene 8.000 documentos de entrenamiento y 2.000 de test. Cada categoría aporta 2.000 ejemplos al train y 500 al test, por lo que no existe desbalance de clases en esta versión del corpus.



Objetivo de negocio o investigación


Automatizar el ruteo temático de noticias para acelerar su organización, búsqueda y análisis. Una solución de este tipo puede alimentar tableros, sistemas de recomendación, monitoreo de medios o pipelines de inteligencia competitiva.

Variable objetivo

Clase	Contenido típico	Riesgo de confusión
World	Política, diplomacia, conflictos y eventos internacionales	Business cuando hay regulación, comercio o empresas
Sports	Competiciones, equipos, atletas y resultados	Bajo: vocabulario muy distintivo
Business	Mercados, adquisiciones, compañías y economía	Sci_Tech en empresas y productos tecnológicos
Sci_Tech	Tecnología, ciencia, software y hardware	Business por lanzamientos, ventas y adquisiciones

El test se reservó para la evaluación final y no intervino en la selección de parámetros de ninguno de los modelos.

2. Pipeline end-to-end y preprocesamiento



El test no participa del ajuste ni de la selección de hiperparámetros

Rama clásica: Scikit-Learn

- Decodificación de entidades HTML y eliminación de etiquetas HTML.
- Sustitución de URLs, dominios y correos electrónicos.
- Normalización a minúsculas y filtrado de caracteres no alfabéticos.
- Stop words en inglés, strip de acentos y normalización L2.
- TfidfVectorizer ajustado exclusivamente con train; sobre test se utilizó transform, nunca fit.

Rama Transformer: Hugging Face


- Tokenizer WordPiece correspondiente a distilbert-base-uncased.
- [CLS] y [SEP] se agregan para delimitar la secuencia y producir una representación de clasificación.
- [PAD] iguala las longitudes dentro del batch; attention_mask distingue tokens reales del padding.
- Truncation activo y longitud máxima de 64 sub-tokens.
- Padding dinámico con DataCollatorWithPadding y múltiplos de 8 para aprovechar GPU.

Diferencia conceptual

TF-IDF representa documentos como frecuencias ponderadas sin conservar el orden. DistilBERT transforma subpalabras en embeddings contextuales y procesa relaciones mediante attention heads. Por ese motivo no se trasladó la lematización agresiva al Transformer: hacerlo eliminaría señales morfológicas y de secuencia útiles para el modelo.

3. Baseline clásico: TF-IDF + LinearSVC

Se eligió LinearSVC porque los clasificadores lineales suelen rendir bien en espacios de texto esparsos y de alta dimensionalidad. La búsqueda de configuración se realizó dentro de train mediante un split estratificado 80/20, con semilla 42.



Componente	Configuración seleccionada
Vectorización	TF-IDF con unigramas y bigramas
max_features	40.000
Vocabulario efectivo	25.886 términos
min_df / max_df	2 / 0,98
sublinear_tf / norm	True / L2
Clasificador	LinearSVC, C=1,0

Precision Macro	Recall Macro	F1 Macro	F1 Weighted	Accuracy
0,8926	0,8925	0,8925	0,8925	0,8925


El modelo cometió 215 errores. La principal confusión fue simétrica: 44 casos Business→Sci_Tech y 44 Sci_Tech→Business. Sports alcanzó el mejor F1 (0,9583); Business fue la clase más difícil (0,8436).

4. Solución avanzada: DistilBERT + PEFT/LoRA

Se seleccionó distilbert-base-uncased porque el corpus está en inglés y porque reduce memoria y tiempo respecto de BERT base. AutoModelForSequenceClassification añadió una cabeza para cuatro etiquetas. Los pesos preentrenados permanecieron congelados y la backpropagation actualizó adaptadores de bajo rango junto con los componentes necesarios de clasificación.

Configuración de LoRA y entrenamiento

Parámetro	Valor	Justificación
Rank r	8	Capacidad moderada para cuatro clases
Alpha	16	Escalado $\alpha/r = 2$
Dropout	0,10	Regularización de adaptadores
Target modules	q_lin, v_lin	Proyecciones query y value de los attention heads
Learning rate	2e-4	Tasa para adaptadores; evita full fine-tuning
Batch	16 train / 32 eval	Compromiso entre memoria y velocidad
Épocas	3	Mejor checkpoint por F1 Macro




Eficiencia paramétrica

Totales	Entrenables	Congelados	Entrenable	Tiempo GPU T4
67.697.672	741.124	66.956.548	1,095%	87,7 s

5. Evaluación comparativa

Modelo	Precision Macro	Recall Macro	F1 Macro	F1 Weighted	Accuracy
TF-IDF + LinearSVC	0,8926	0,8925	0,8925	0,8925	0,8925
DistilBERT + LoRA	0,9076	0,9070	0,9070	0,9070	0,9070
Diferencia	+0,0150	+0,0145	+0,0146	+0,0146	+0,0145




F1 Macro y F1 Weighted coinciden porque las cuatro clases poseen el mismo soporte. Aun así, ambos se reportan para cumplir la consigna y mantener comparabilidad si la distribución cambia en producción.


Comparación por clase

Clase	F1 baseline	F1 LoRA	Diferencia	Lectura
World	0,8934	0,9106	+0,0172	Mejora general
Sports	0,9583	0,9741	+0,0158	Mayor calidad absoluta
Business	0,8436	0,8483	+0,0047	Ganancia pequeña
Sci_Tech	0,8746	0,8952	+0,0206	Mayor ganancia relativa

5.1. Desempeño por clase y matrices comparadas



Matrices de confusión sobre el mismo ag_news_test.csv



Lectura de las matrices

- El baseline acertó 1.785/2.000 noticias; LoRA acertó 1.814/2.000: 29 aciertos adicionales.
- LoRA aumentó los aciertos de Sci_Tech de 436 a 457 y redujo Sci_Tech→Business de 44 a 35.
- Business→Sci_Tech aumentó de 44 a 52. La mejora global no fue uniforme en todas las direcciones de error.
- Sports pasó de 483 a 489 aciertos y mantuvo la mayor separabilidad temática.

Las matrices usan el mismo orden de clases y el mismo ag_news_test.csv. Por ello, las diferencias observadas son comparables directamente.

5.2. Interpretabilidad y análisis cualitativo

TF-IDF permite inspeccionar términos y pesos lineales, pero no representa el orden ni el significado contextual. DistilBERT utiliza embeddings contextuales y self-attention; una misma palabra puede adoptar representaciones distintas según las palabras vecinas. La mejora agregada de Sci_Tech es compatible con una mejor lectura del contexto, aunque este experimento no calculó atribuciones de atención y no demuestra causalmente qué token produjo cada decisión.

Ejemplos reales de errores del baseline

Texto resumido	Real	Baseline	Interpretación
Symantec ... talks to acquire Veritas Software, a maker of data backup programs	Business	Sci_Tech	Software domina el vocabulario, pero el evento central es una adquisición corporativa.
EU regulators approve Oracle's \$7.7bn bid for PeopleSoft	Sci_Tech	Business	Regulación y adquisición activan señales financieras; las entidades tecnológicas sostienen Sci_Tech.
Maddux pitched the Cubs ... NL wild-card race ... 302nd career win	World	Sports	El texto es inequívocamente deportivo; la etiqueta World sugiere ruido o ambigüedad del dataset.
Google founders selling stock ... search engine ... shares	Sci_Tech	Business	Producto tecnológico y mercado bursátil conviven; requiere ponderar el foco global de la noticia.

Estos ejemplos documentan errores reales del baseline y muestran por qué el contexto puede ser relevante. No se dispone de predicciones pareadas por observación para afirmar que LoRA corrigió específicamente cada uno; la evidencia sólida de LoRA en este informe es agregada y por clase.

Eficiencia frente a desempeño

Dimensión	TF-IDF + LinearSVC	DistilBERT + LoRA
Desempeño	F1 Macro 0,8925	F1 Macro 0,9070
Entrenamiento	CPU; tiempo no instrumentado	GPU T4; 87,7 segundos
Representación	Matriz esparsa de 25.886 términos	Embeddings contextuales y atención
Interpretabilidad	Alta: términos y coeficientes	Menor sin métodos de atribución
Despliegue	Simple y liviano	Mayor memoria y latencia
Actualización	Reentrenamiento económico	PEFT: 1,095% entrenable

6. Reproducibilidad y calidad de evidencia

La comparación fue diseñada para evitar data leakage y diferencias de población. Los dos modelos comparten el mismo train oficial y el mismo test oficial. La selección de hiperparámetros se realizó solo dentro de train.

Checklist metodológico

Control	Evidencia	Estado
Mismos archivos	ag_news_train.csv y ag_news_test.csv para ambos modelos	Cumplido
Test aislado	No participa del fit, validación ni selección	Cumplido
Orden de clases	World, Sports, Business, Sci_Tech	Cumplido
Semilla	42	Cumplido
Baseline	fit_transform solo en train; transform en test	Cumplido
Transformer	train 6.400; validación 1.600; test 2.000	Cumplido
Métricas	Precision, Recall, F1 Macro, F1 Weighted y Accuracy	Cumplido
Evidencias	JSON, CSV, historial y matrices reconciliadas	Cumplido
PDF	Renderizado y revisado visualmente página por página	Cumplido

Spot-check independiente

Las métricas de LoRA se recalcularon desde su matriz de confusión: $1.814/2.000 = 0,9070$ de Accuracy; Precision Macro 0,9076 y F1 Macro 0,9070. Los resultados coinciden con metrics_lora.json, classification_report_lora.csv y model_comparison.csv.

Riesgos residuales

- El tiempo exacto del baseline no quedó registrado.
- No se almacenaron predicciones pareadas del Transformer por observación.
- El experimento se ejecutó con una única semilla y una única configuración LoRA.
- No se midieron latencia de inferencia, memoria máxima ni tamaño final de artefactos de ambos modelos.

7. Conclusiones y recomendación final

Hallazgo principal

DistilBERT + LoRA fue el modelo con mejor calidad predictiva. Elevó el F1 Macro de 0,8925 a 0,9070 y la Accuracy de 0,8925 a 0,9070, con 29 aciertos adicionales. El salto es estadísticamente descriptivo para este test; no se estimó un intervalo de confianza ni variabilidad entre seeds.

Recomendación defendible

Se recomienda LoRA cuando la prioridad es maximizar desempeño y existe infraestructura compatible con Transformers. Para un despliegue real se sugiere conservar TF-IDF + LinearSVC como baseline de monitoreo y fallback. Si la mejora de 1,46 puntos no compensa latencia o memoria, el modelo clásico puede ser la decisión más eficiente.

Por qué LoRA mejora

TF-IDF aprende asociaciones entre etiquetas y términos o n-gramas. DistilBERT parte de embeddings preentrenados y modela dependencias de la secuencia con atención. LoRA modifica de forma compacta las proyecciones query y value, adaptando ese conocimiento contextual al dominio de AG News sin actualizar todos los pesos.

Limitaciones

- Muestra reducida frente al AG News completo.
- Un único checkpoint, seed y conjunto de hiperparámetros LoRA.
- Longitud máxima de 64 sub-tokens, con posible truncamiento de casos largos.
- Interpretabilidad contextual cualitativa, sin mapas de atención, Integrated Gradients o SHAP.
- Sin benchmark completo de latencia, memoria, energía y tamaño de artefactos.

Líneas futuras

- Repetir con varios seeds y reportar media, desvío e intervalos.
- Evaluar $r = 4, 8$ y 16 , distintos target_modules y checkpoints como RoBERTa o DeBERTa.
- Guardar probabilidades y predicciones pareadas para análisis por ejemplo.
- Aplicar métodos de atribución para inspeccionar tokens relevantes.
- Medir latencia, memoria e inferencias por segundo en el entorno objetivo.
- Monitorear drift de vocabulario, distribución de clases y degradación del F1 Weighted.

8. Referencias y trazabilidad

Referencias técnicas

1. Hu, E. J. et al. (2021). LoRA: Low-Rank Adaptation of Large Language Models. arXiv:2106.09685. <https://arxiv.org/abs/2106.09685>
2. Sanh, V. et al. (2019). DistilBERT, a distilled version of BERT. arXiv:1910.01108. <https://arxiv.org/abs/1910.01108>
3. Zhang, X., Zhao, J. y LeCun, Y. (2015). Character-level Convolutional Networks for Text Classification. NeurIPS. <https://arxiv.org/abs/1509.01626>
4. Hugging Face. Transformers Trainer documentation. https://huggingface.co/docs/transformers/main_classes/trainer
5. Hugging Face. PEFT documentation. <https://huggingface.co/docs/peft/>
6. Scikit-Learn. TfidfVectorizer and LinearSVC documentation. <https://scikit-learn.org/stable/>

Repositorio complementario

Código, configuración y evidencias reproducibles: <https://github.com/mnoero23/Data-Scientist-III>

Correspondencia con los criterios de aceptación

Criterio	Dónde se resuelve	Estado
Integración end-to-end	Secciones 1 a 7 y diagrama del pipeline	Cumplido
Preprocesamiento comparado	Sección 2: Scikit-Learn vs. Hugging Face	Cumplido
Profundidad técnica	Backpropagation, embeddings, attention heads y rank	Cumplido
Mismo test	Secciones 1, 2, 5 y 6	Cumplido
Métricas completas	Precision, Recall, F1 Macro/Weighted y Accuracy	Cumplido
Matrices comparadas	Sección 5.1	Cumplido
Eficiencia	Secciones 4 y 5.2	Cumplido con caveat
Interpretabilidad	Sección 5.2; ejemplos y limitación explícita	Cumplido
Conclusiones y referencias	Secciones 7 y 8	Cumplido
PDF único	Este documento	Cumplido

Nota final

Este informe sintetiza toda la evidencia relevante. Los enlaces externos se incluyen únicamente como referencia secundaria y no son necesarios para interpretar los resultados ni evaluar el cumplimiento del proyecto.