

DATA SCIENTIST III

# NLP & Deep Learning

Resumen integral del curso y del proyecto final

---

**De los fundamentos de redes neuronales a una comparación reproducible entre TF-IDF y un Transformer ajustado con LoRA.**

Matías Noero  
Coderhouse · 2026

# El recorrido en una mirada

El curso construyó una solución completa de clasificación de noticias: primero el ciclo de entrenamiento, luego el corpus, después el baseline clásico y finalmente el modelo contextual. El capstone unificó todo sobre el mismo conjunto de prueba.

| Etapa    | Producto principal       | Resultado                          |
|----------|--------------------------|------------------------------------|
| Módulo 1 | Pipeline PyTorch         | 93,33% accuracy de validación      |
| Módulo 2 | Corpus AG News preparado | 8.000 train · 4 clases balanceadas |
| Módulo 3 | TF-IDF + LinearSVC       | F1 weighted 0,8925                 |
| Módulo 4 | DistilBERT + LoRA        | F1 weighted 0,9070                 |
| Módulo 5 | Capstone comparativo     | 12 páginas · evidencia consolidada |

## Resultado final

**LoRA obtuvo 1.814 aciertos sobre 2.000 noticias, 29 más que el baseline. La mejora de 1,46 puntos porcentuales en F1 weighted justifica el modelo avanzado cuando prima la calidad predictiva, sin invalidar el valor operativo del baseline.**

# Módulo 1 · Fundamentos de Deep Learning

- Perceptrón, activaciones y no linealidad.
- Arquitectura de redes, forward pass y funciones de pérdida.
- Backpropagation, regla de la cadena y descenso de gradiente.
- PyTorch: tensores, autograd, optimizadores y validación.

**Producto: Pipeline base validado: 93,33% de accuracy y loss 0,1689.**

---

## Módulo 2 · NLP y preparación de texto

- Datos no tabulares y problemas reales de NLP.
- Regex, normalización, stopwords, stemming y lematización.
- Tokenización por palabras y subpalabras; manejo de OOV.
- EDA del corpus y control de longitudes y balance.

**Producto: Corpus AG News: 8.000 noticias de train, 4 clases balanceadas y P95 de 32 tokens.**

## Módulo 3 · Modelos clásicos para NLP

- Bag of Words, TF-IDF, vocabulario y n-gramas.
- Naive Bayes, Regresión Logística, SVM y LinearSVC.
- Precision, Recall, F1, thresholding y matrices de confusión.
- Sentimiento con VADER y tópicos con LDA.

**Producto: Baseline elegido: TF-IDF + LinearSVC, F1 weighted 0,8925.**

---

## Módulo 4 · Transformers y fine-tuning eficiente

- RNN, LSTM y GRU para dependencias secuenciales.
- Self-attention, embeddings contextuales y attention heads.
- Hugging Face: tokenización, Trainer y evaluación.
- LoRA/PEFT para adaptar modelos con pocos parámetros.

**Producto: DistilBERT + LoRA: F1 weighted 0,9070 con solo 1,095% de parámetros entrenables.**

# Comparación técnica final

| Modelo             | Prec. macro | Recall macro | F1 macro | F1 weighted | Accuracy |
|--------------------|-------------|--------------|----------|-------------|----------|
| TF-IDF + LinearSVC | 0,8926      | 0,8925       | 0,8925   | 0,8925      | 0,8925   |
| DistilBERT + LoRA  | 0,9076      | 0,9070       | 0,9070   | 0,9070      | 0,9070   |

## Lectura del resultado

- La comparación es válida porque ambos modelos usan el mismo ag\_news\_test.csv de 2.000 casos.
- Sports es la categoría más separable; la dificultad central está entre Business y Sci\_Tech.
- LoRA gana en desempeño contextual; TF-IDF conserva ventajas de simplicidad, velocidad e interpretabilidad léxica.
- El tiempo del baseline no fue instrumentado y no se presenta una cifra inventada.
- La interpretabilidad del Transformer es cualitativa; no se atribuyen decisiones a atención sin evidencia específica.

## Configuración LoRA

| Elemento               | Valor                          |
|------------------------|--------------------------------|
| Modelo base            | distilbert-base-uncased        |
| Rank / alpha / dropout | 8 / 16 / 0,1                   |
| Target modules         | q_lin y v_lin                  |
| Learning rate / épocas | 2e-4 / 3                       |
| Parámetros entrenables | 741.124 de 67.697.672 (1,095%) |
| Entrenamiento          | 87,712 s en GPU T4             |

# Competencias consolidadas

- Diseñar ciclos reproducibles de entrenamiento y validación con PyTorch.
- Preparar y auditar corpus de texto evitando data leakage.
- Elegir representaciones y modelos según desempeño, costo e interpretabilidad.
- Diagnosticar clasificadores mediante F1, matrices de confusión y análisis por clase.
- Entrenar Transformers con Hugging Face y aplicar LoRA para fine-tuning eficiente.
- Comparar modelos sobre una población común y documentar límites de la evidencia.
- Comunicar una solución técnica como problema, método, resultado y decisión.

## Buenas prácticas que quedan como guía

- Separar train, validation y test antes de ajustar transformaciones.
- Ajustar TF-IDF solo sobre train y reutilizar la transformación sobre test.
- Mantener un baseline simple como punto de comparación.
- Registrar semillas, versiones, hiperparámetros y tiempos desde el comienzo.
- Usar el mismo test para cualquier comparación que se pretenda defender.
- No confundir visualización de atención con explicación causal del modelo.

## Próximos pasos

- Subir el capstone a Coderhouse y registrar la devolución final.
- Congelar versiones exactas y agregar una ruta de inferencia sobre texto nuevo.
- Incorporar predicciones pareadas y explicabilidad con SHAP, LIME o atribución compatible.
- Convertir el proyecto en una pieza de portfolio orientada a un caso de negocio.

# Cierre

**El valor del curso no está solo en haber entrenado dos modelos. Está en haber aprendido a construir una comparación defendible: misma población, métricas adecuadas, trazabilidad, límites explícitos y una decisión técnica proporcional al problema.**

**Modelo recomendado para desempeño**

**DistilBERT + LoRA**

**Baseline recomendado para simplicidad e interpretación**

**TF-IDF + LinearSVC**

Fuentes: notas y entregas de Data Scientist III en Notion; resultados de los proyectos PyTorch, TF-IDF y LoRA; informe técnico final consolidado.